

LAPORAN TUGAS

APACHE AIRFLOW DAG - ETL PIPELINE SEDERHANA

Pipeline ETL Dataset Penjualan Retail

Nama : Hikmah Nursidik
NIM : 25/573877/PPA/07227
DAG ID : etl_sederhana_25573877PPA07227

1. Deskripsi Dataset dan Tujuan Pipeline

Proyek menggunakan data penjualan retail sintetis berbentuk CSV. Data dasar berisi 315 transaksi selama tahun 2025 dengan kolom `sale_id`, `sale_date`, `product_id`, `product_name`, `quantity`, `unit_price`, `total_amount`, dan `city`. Baris *null* dan *duplicate* sengaja ditambahkan agar data menyerupai sumber operasional yang belum bersih dan membutuhkan proses ETL.

Pipeline mengambil data dari folder raw, memvalidasi kualitasnya, membersihkan record bermasalah, membuat dua agregasi, menghasilkan visualisasi, dan menyimpan hasil akhir yang siap dianalisis. Pipeline juga menyimpan log terpisah untuk setiap trigger agar proses dapat ditelusuri.

Tabel 1. 1 Struktur Dataset

Kolom	Fungsi
<code>sale_id</code>	Identitas transaksi
<code>sale_date</code>	Dimensi waktu
<code>product_id</code> , <code>product_name</code>	Identitas produk
<code>quantity</code> , <code>unit_price</code>	Kuantitas dan harga
<code>total_amount</code>	Nilai transaksi
<code>city</code>	Lokasi transaksi

2. Rancangan Pipeline

```
extract_data >> validate_data >> transform_data >> load_data
```

Dependency berurutan memastikan data tidak divalidasi sebelum diekstrak, tidak ditransformasi sebelum divalidasi, dan tidak dimuat sebelum hasil transformasi tersedia. Seluruh task menggunakan PythonOperator.

3. Penjelasan Task dan Logika Transformasi

3.1 Extract – `extract_data`

Memastikan `data/raw/sales.csv` tersedia, membuat folder staging, menyalin file menjadi `sales_staging.csv`, menghitung jumlah record, dan mencatat aktivitas ke `extract.log`.

3.2 Validate - *validate_data*

Memeriksa header, kolom wajib, nilai null, duplikat identik, sale_id ganda, tipe numerik, serta format tanggal YYYY-MM-DD. Temuan kualitas data dicatat sebagai warning dan selanjutnya ditangani pada tahap Transform.

3.3 Transform - *transform_data*

Membersihkan data dengan `safe_int()`, `safe_float()`, dan `parse_date()`. Record dengan field kritis kosong atau tidak valid dilewati. Duplikat penuh dan sale_id ganda dihapus. Kota kosong diisi Unknown dan nama produk kosong diisi Unknown Product.

3.4 Load - *load_data*

Memindahkan dua hasil agregasi dari staging ke folder output, menghitung jumlah baris output, memverifikasi file visualisasi, dan mencatat hasil ke load.log. Jika total_amount kosong, negatif, bukan angka, atau berbeda lebih dari 0,01 dari nilai yang dihitung, pipeline menggunakan rumus berikut:

$$expected_total = quantity * unit_price$$

Agregasi pertama menghasilkan total transaksi, kuantitas, dan penjualan per tanggal. Agregasi kedua menghasilkan metrik yang sama per kota dan diurutkan berdasarkan total penjualan terbesar.

Tabel 3. 1 Hasil Agregasi


Output	Isi
sales_daily.csv	Agregasi penjualan per tanggal
sales_by_city.csv	Agregasi penjualan per kota
sales_daily_trend.png	Grafik garis tren penjualan harian
sales_by_city.png	Grafik batang penjualan per kota

4. Logging dan Reusability


Setiap DAG run membuat folder berdasarkan logical_date dan run_id. Keempat task pada run yang sama menulis ke folder yang sama, sedangkan trigger berikutnya membuat folder baru. File staging dan output ditimpa secara aman pada re-run, dan max_active_runs=1 mencegah dua run menulis target yang sama secara bersamaan.

`data/logs/<logical_date>__<run_id>/`
`extract.log | validate.log | transform.log | load.log`

5. Bukti Eksekusi dan Hasil




Gambar 5.1 Graph View DAG



Gambar 5.2 Log task sukses

```
data > output > sales_daily.csv
1 sale_date,total_transactions,total_quantity,total_sales
2 2025-01-04,1,2,900000.0
3 2025-01-05,1,5,2250000.0
4 2025-01-07,1,1,1800000.0
5 2025-01-11,1,5,2250000.0
6 2025-01-12,1,3,1050000.0
7 2025-01-13,2,6,900000.0
8 2025-01-14,1,5,2250000.0
9 2025-01-17,1,3,5400000.0
10 2025-01-19,2,10,9750000.0
11 2025-01-23,1,4,600000.0
12 2025-01-24,1,3,450000.0
13 2025-01-26,1,4,1800000.0
14 2025-01-27,1,2,700000.0
15 2025-01-29,1,3,450000.0
16 2025-02-02,1,2,300000.0
17 2025-02-04,1,2,1500000.0
```

Gambar 5.3 Contoh output CSV



Gambar 5.4 Visualisasi hasil

6. Kendala dan Penyelesaian

Tabel 6. 1 Kendala dan Penyelesaian

Kendala	Penyelesaian
ValueError saat int("")	Menggunakan safe_int() dan safe_float() sebelum konversi.
Duplikat ikut teragregasi	Menerapkan deduplikasi seluruh record dan sale_id.
Matplotlib belum tersedia	Menambahkan Matplotlib ke Dockerfile lalu rebuild image.
Log antar-trigger tercampur	Membuat folder berdasarkan logical_date dan run_id.

7. Kesimpulan

Pipeline ETL penjualan retail telah dirancang dengan empat task utama dan dependency yang sesuai. Pipeline mampu memvalidasi null dan duplikat, menangani konversi nilai kosong, menghitung ulang total transaksi, membuat agregasi harian dan kota, menghasilkan visualisasi, serta menyimpan log per trigger.

Repository GitHub: [ETL Sederhana – Hikmah Nursidik](#)

Referensi: Apache Airflow Documentation; Matplotlib Documentation; Docker Documentation; Python Documentation.